Qual é o tok/s desta máquina?

29,8	37,0	37,1	36,9	33,2

O que se mede em uma requisição

Métrica	O que é	Nosso dado
TTFT	Tempo até o primeiro token	43 ms
TPOT	Tempo médio por token depois do primeiro	29 ms
ITL	Intervalo entre tokens consecutivos (p50 / p95)	28 / 38 ms
Decode Rate	Tokens por segundo depois do primeiro	34,8 tok/s

Qwen2.5 0.5B Q4_K_M · llama.cpp server · 128 tokens · média de 5 execuções · notebook-pedro

A média não conta a história

Sessão 1

36,1 ± 5,9

tok/s · de 29,8 a 45,5

Sessão 2

34,8 ± 3,3

tok/s · de 29,8 a 37,1

Mesma máquina, mesmo container, mesmo prompt. As médias diferem em **1,3 tok/s**, menos que o desvio de cada sessão.

Decode, 5 execuções por sessão · desvio = desvio padrão amostral

Benchmark e testbench

Benchmark

A pergunta padronizada: tarefa, dados e métrica fixos para comparar sistemas.

Testbench

A bancada: controla as condições, mede e registra tudo para a medição ser repetida.

O nosso: **bench.py** + **compose.yaml** mais o JSON de procedência.

Procedência: o que registrar

Campo do JSON	Responde a
imagem_docker_digest	Qual servidor rodou
script_sha256	Qual medidor foi usado
prompt_sha256, seed, temperature	Qual foi a entrada
cpu, ram_gb, arquitetura	Onde rodou
notas	Modo de energia e condições

Nosso primeiro JSON saiu com o digest vazio. Só apareceu porque alguém abriu o arquivo.

O que o container garante

Garante

- Mesmo servidor (digest)
- Mesmo script de medição
- Mesma entrada e mesmos parâmetros

Não garante

- Mesmo hardware, clock e térmica
- Mesmos pesos (baixados na hora, sem hash)
- Mesma RAM (no Docker Desktop é a da VM)

Por isso "funciona na minha máquina" deixa de ser desculpa: a diferença passa a ser **atribuível**.

Passagem para a demo da Beatriz: mesmo container em duas máquinas

Quando uma diferença vale?

Só quando é maior que o ruído entre execuções.

Nosso caso: 36,1 contra 34,8 é diferença de 1,3 com desvio de 3 a 6. Não dá para dizer que uma sessão é melhor.