CEIA
CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

O que é um modelo de linguagem: Tokens, vocabulário, embeddings

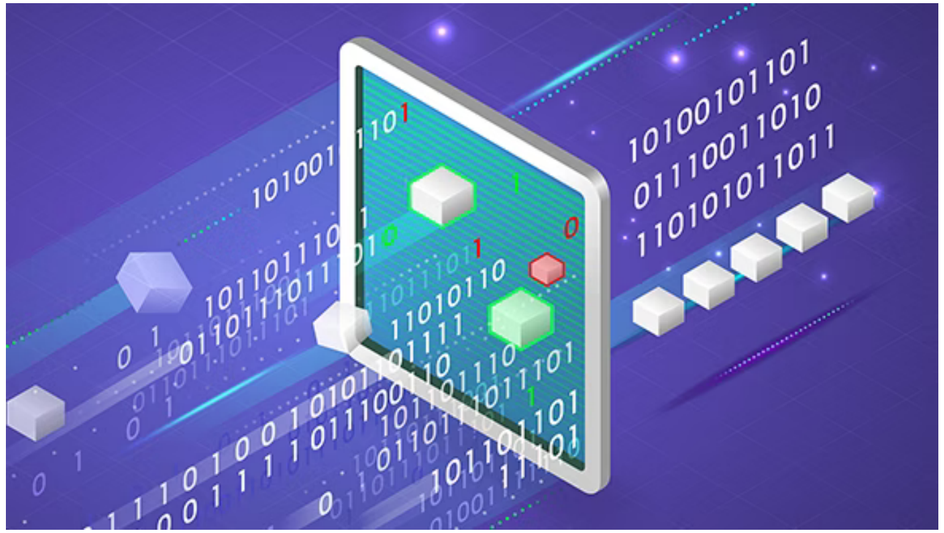
Semana 4

Responsável: Marcos Vinicius

Explicando tokens: A linguagem e a moeda da IA

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Tokens são unidades de dados processadas por modelos de IA durante o treinamento e inferência, permitindo previsão, geração e raciocínio.



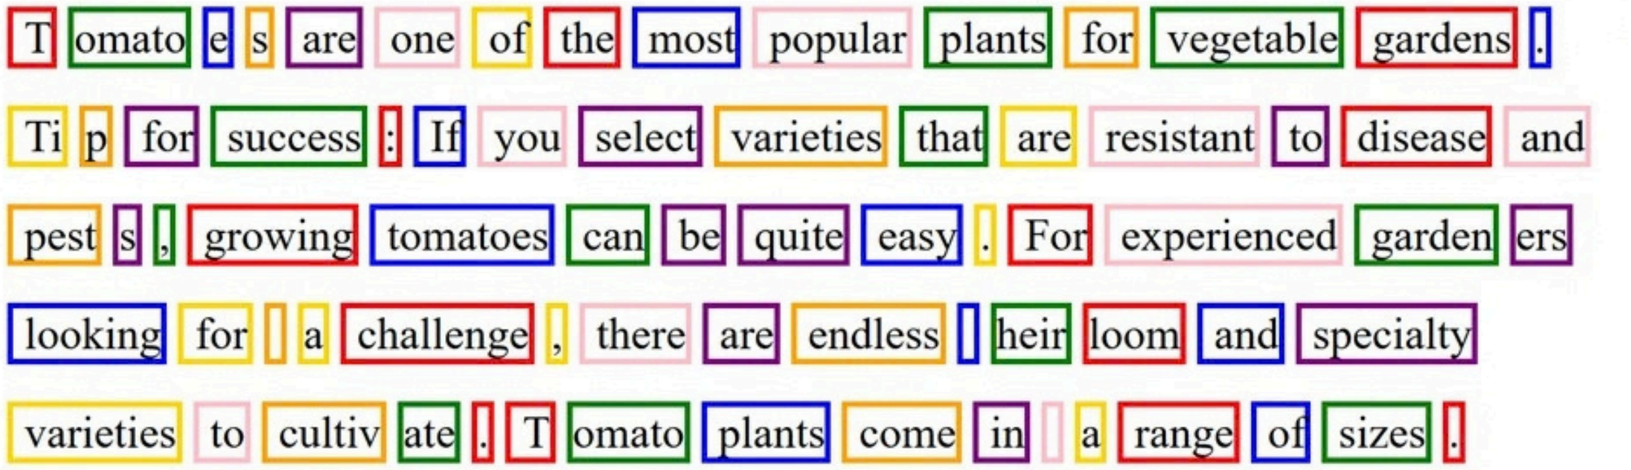
O que é tokenização?

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Se um modelo transformer de IA está processando texto, imagens, clipes de áudio, vídeos ou outra modalidade, ele traduzirá os dados em tokens. Esse processo é conhecido como tokenização.

A tokenização eficiente ajuda a reduzir a quantidade de poder de computação necessária para treinamento e inferência. Existem vários métodos de tokenização, e os tokenizadores adaptados para tipos de dados e casos de uso específicos podem exigir um vocabulário menor, o que significa que há menos tokens para processar. Para grandes modelos de linguagem(LLMs), palavras curtas podem ser representadas com um único token, enquanto palavras mais longas podem ser divididas em dois ou mais tokens.

A palavra darkness, por exemplo, seria dividida em dois tokens, “dark” e “ness”, com cada token tendo uma representação numérica, um TOKEN ID, como 217 e 655. A palavra oposta, brightness, seria igualmente dividida em “bright” e “ness”, com representações numéricas correspondentes de 491 e 655.



Como os tokens são usados durante o treinamento de IA?

O treinamento de um modelo de IA começa com a tokenização do conjunto de dados de treinamento. Com base no tamanho dos dados de treinamento, o número de tokens pode chegar a bilhões ou trilhões

Como os tokens são usados durante a inferência e o raciocínio da IA?

Durante a inferência, uma IA recebe um prompt que, dependendo do modelo, pode ser texto, imagem, vídeo, O modelo processa esses tokens de entrada, gera sua resposta como tokens e, em seguida, a converte para o formato esperado do usuário.



O que são vocabulários em modelos de linguagem ?

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Nos modelos de linguagem, vocabulário é o conjunto finito de tokens que o modelo consegue representar e manipular. O modelo não recebe texto bruto: o tokenizador quebra o texto em tokens, e cada token é convertido em um ID numérico. Esses IDs são o que o modelo realmente “vê”.

Qual é o papel do vocabulário no modelo?

O vocabulário é o “alfabeto” do modelo. O tamanho do vocabulário de um LLM, ou seja, a quantidade de palavras, sílabas ou subpalavras (tokens) únicas que ele consegue reconhecer e processar, impacta diretamente o custo financeiro, a velocidade de processamento, a eficiência de memória e a capacidade de compreensão linguística do modelo.



SLMs (Small Language Models) usam vocabulários menores para economizar memória — mas precisam de mais tokens para dizer a mesma coisa.

⚖️ O Trade-off Central

✅ Vocabulário GRANDE

- Palavras raras cabem em 1 token
- Textos ficam mais curtos (menos tokens)
- Melhor para múltiplos idiomas

💾 **Custa mais memória**

✅ Vocabulário PEQUENO

- Economiza memória (bom para SLMs!)
- Treina mais rápido
- Mais fácil de implantar em dispositivos

🔪 **Textos ficam mais longos**

💡 **Resumo:** O vocabulário é o **alfabeto de peças** que o modelo pode usar. É finito, pré-definido e fundamental para equilibrar capacidade vs. eficiência.

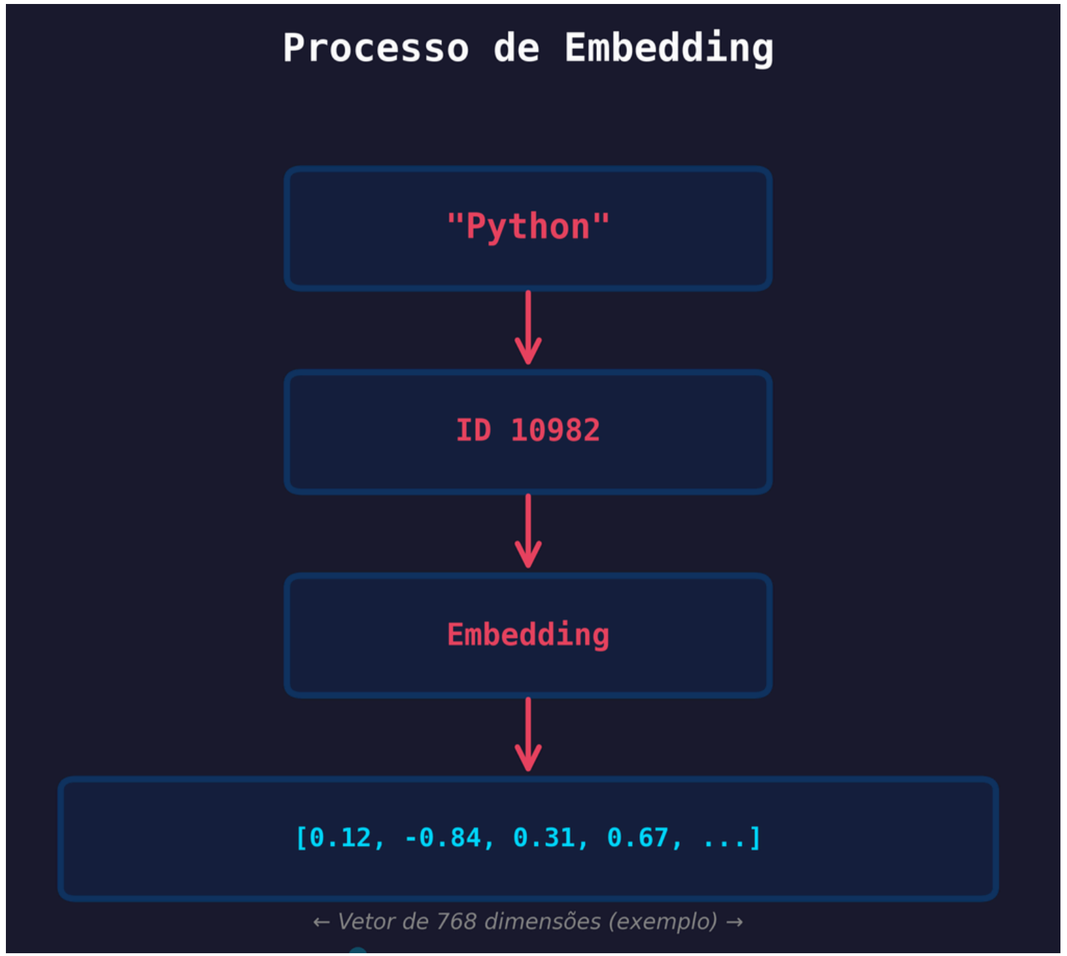
O que é embadding ? (incorporação)

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Embedding é um método para representar objetos, como textos, imagens e áudios, como pontos em um espaço vetorial contínuo, onde as localizações desses pontos têm significado semântico para algoritmos de aprendizado de máquina.

Em essência, o embedding permite que os modelos de aprendizado de máquina encontrem objetos similares.

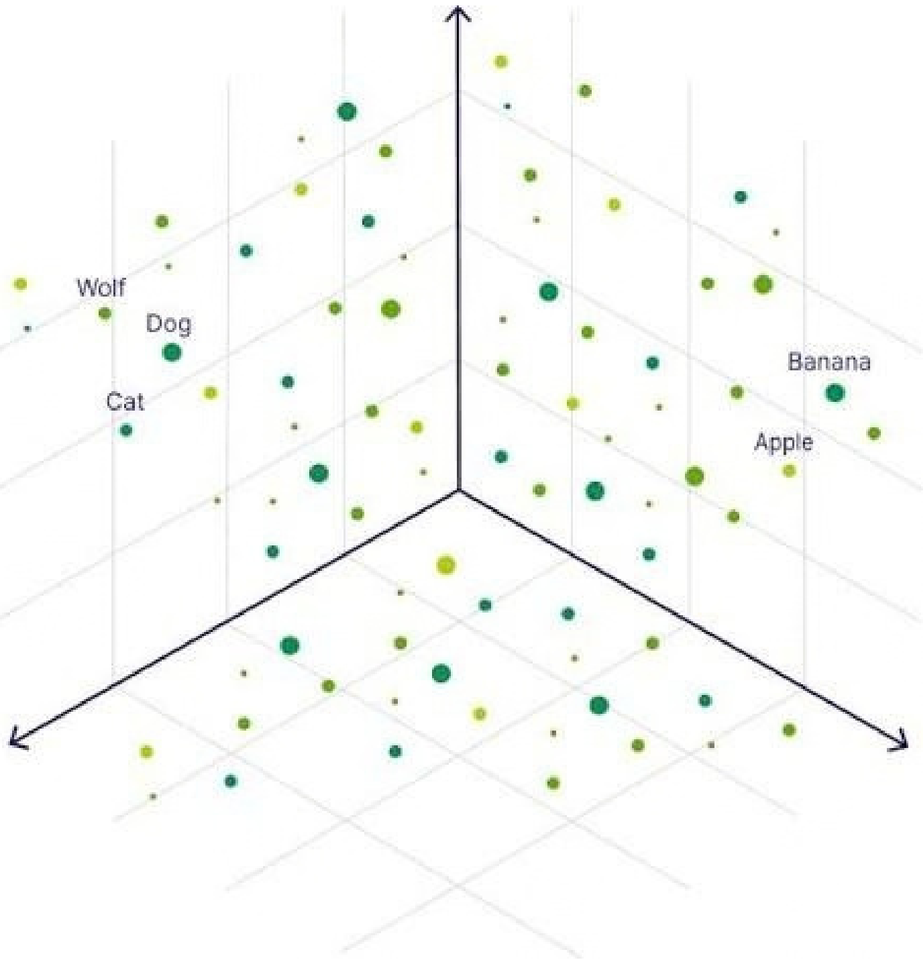
A maioria dos métodos de embedding se resume a transformar uma palavra ou token em um vetor.



O que diferencia as técnicas de embedding umas das outras é a forma como abordam essa conversão de palavra para vetor. Embeddings não se limitam a texto; podem ser aplicados a imagens, áudio ou até mesmo dados de grafos. De forma geral, embedding é o processo de converter dados [de qualquer tipo] em vetores.

Por que usar o embedding ?

Os embeddings são amplamente utilizados em diferentes domínios e aplicações devido à sua capacidade de transformar dados de alta dimensão e categóricos em representações vetoriais contínuas, capturando padrões, relações e significados relevantes.



Mas o que torna uma técnica de embedding boa?

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Em outras palavras, o que caracteriza um embedding ideal? Aqui estão duas propriedades principais de uma técnica de embedding:

Representação Semântica: Alguns tipos de embeddings capturam a relação semântica entre palavras. Isso significa que palavras com significados ou relações mais próximos ficam mais perto no espaço vetorial do que palavras menos relacionadas. Por exemplo, os vetores de "gato" e "cachorro" devem ser mais semelhantes entre si do que os de "cachorro" e "morango".

Dimensionalidade: Qual deve ser o tamanho de um vetor de embedding: 15, 50 ou 300? Encontrar o equilíbrio certo é fundamental. Vetores menores (dimensões mais baixas) são mais eficientes para armazenamento em memória ou processamento, enquanto vetores maiores (dimensões mais altas) conseguem capturar relações complexas, mas são mais suscetíveis ao overfitting (sobreajuste). Para referência, a família de modelos GPT-2 utiliza um tamanho de embedding de pelo menos 768.

Pergunta da semana

Uma mesma frase em português custa quantos tokens a mais que em inglês? O que isso faz com o tempo de resposta que o usuário sente?

CENTRO DE EXCELÊNCIA EM INTELIGÊNCIA ARTIFICIAL

Os LLMs não processam texto diretamente, eles o dividem em tokens, que são pequenas unidades. O custo é contado por tokens, não por caracteres.

Inglês: "How are you today?"
→ ~4 tokens

Português: "Como você está hoje?"
→ ~6-7 tokens
(proporcionalmente mais)

A raiz está principalmente em como o tokenizador foi construído

Sobre o tempo de resposta

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Entrada de tokens: Mais tokens significam mais trabalho no processamento inicial (prefill). Isso pode aumentar um pouco a latência antes de começar a aparecer a resposta.

Saída de tokens: Aqui o impacto pode ser mais perceptível. Durante o decode, o modelo normalmente produz os tokens sequencialmente. Se português exige mais tokens para dizer a mesma coisa, há mais passos de geração.

Referências

CENTRO DE EXCELÊNCIA
EM INTELIGÊNCIA ARTIFICIAL

Quer ver a fundo as técnicas tradicionais de embedding? acesse:
https://huggingface.co/spaces/hesamation/primer-llm-embedding?section=what_are_embeddings%3F

Outros: https://blog.nvidia.com.br/blog/tokens-ia-explicados/

Outros: https://www.ibm.com/br-pt/think/topics/embedding

Obrigado!

Por favor, façam perguntas!

