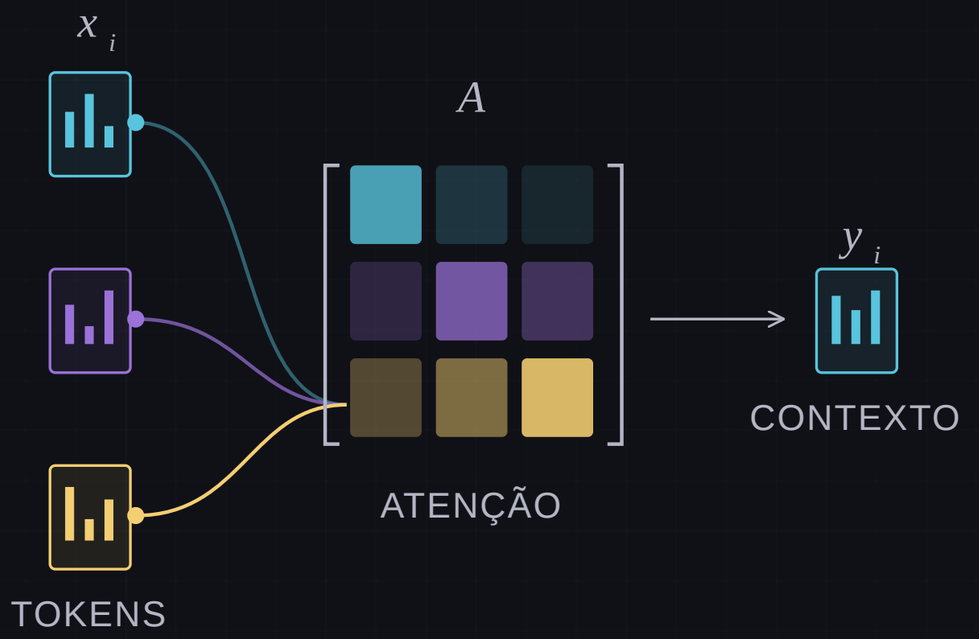
— SEMANA 05 · TRANSFORMER

Transformer *por dentro.*

Atenção, pesos e funções de ativação.

A PERGUNTA QUE GUIA A AULA

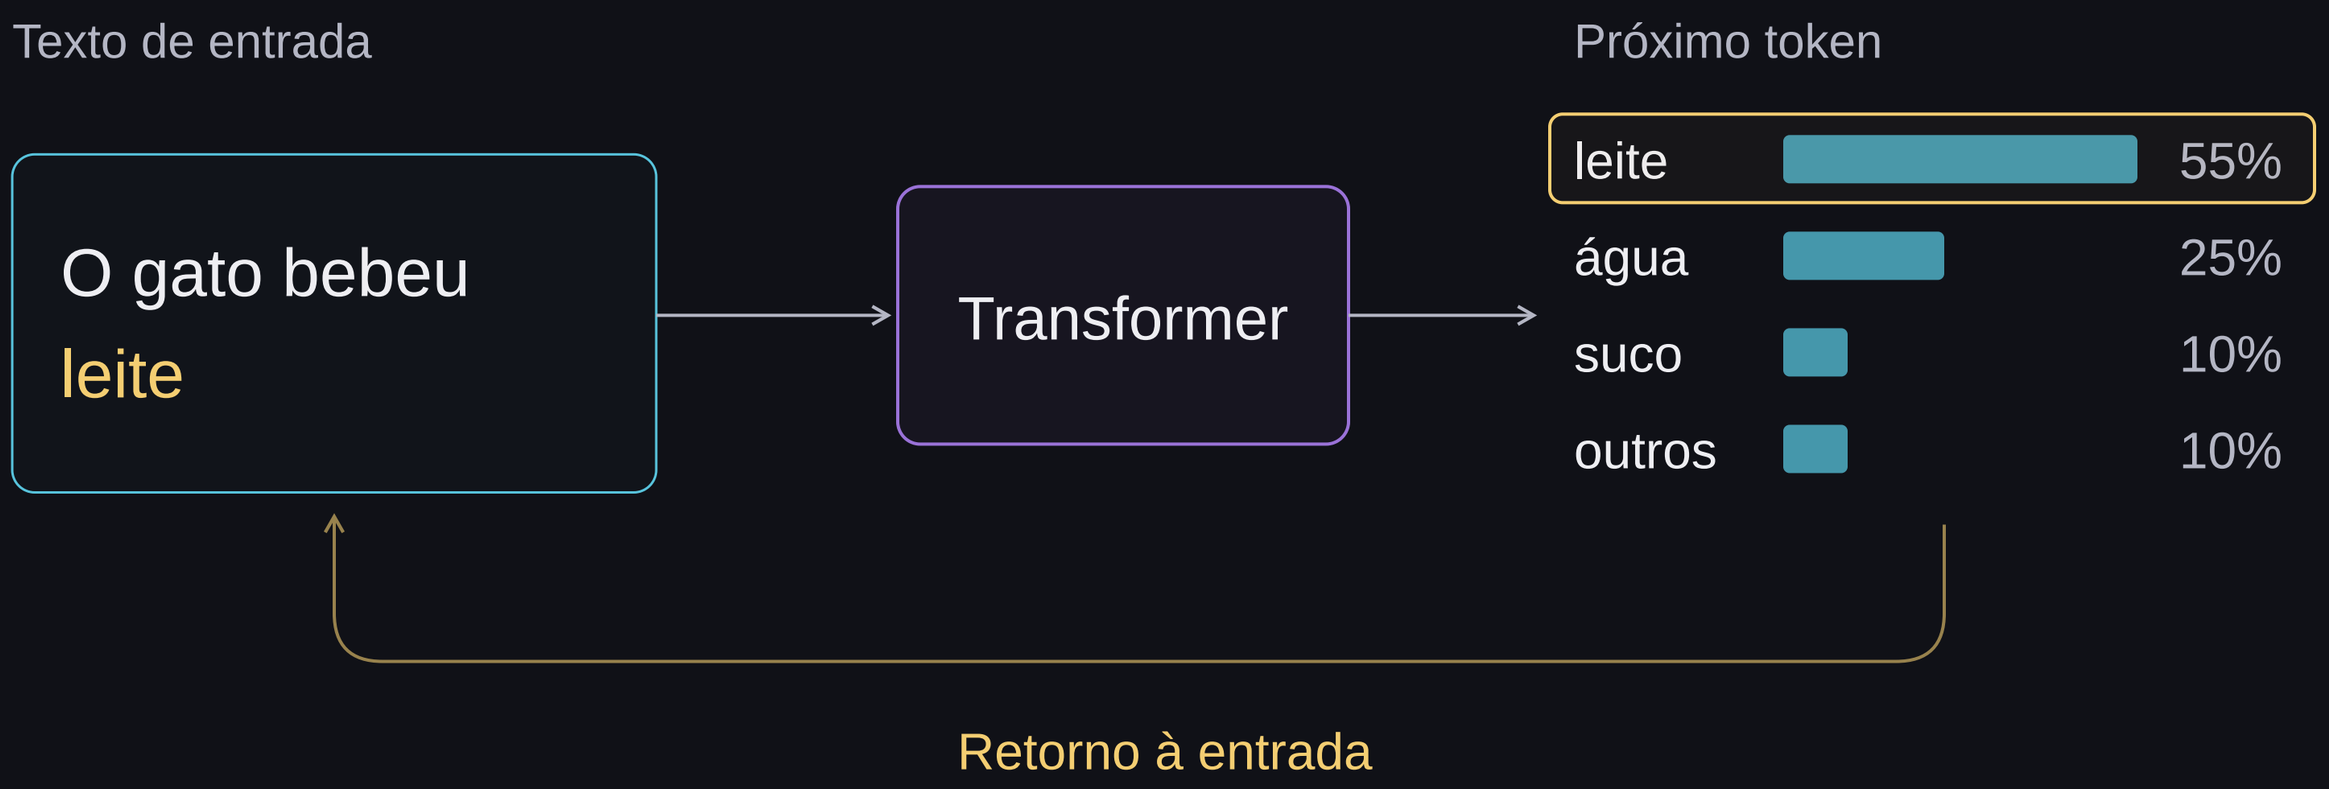
Onde estão os parâmetros de um modelo de 1 bilhão?



$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

— UMA PREVISÃO POR VEZ

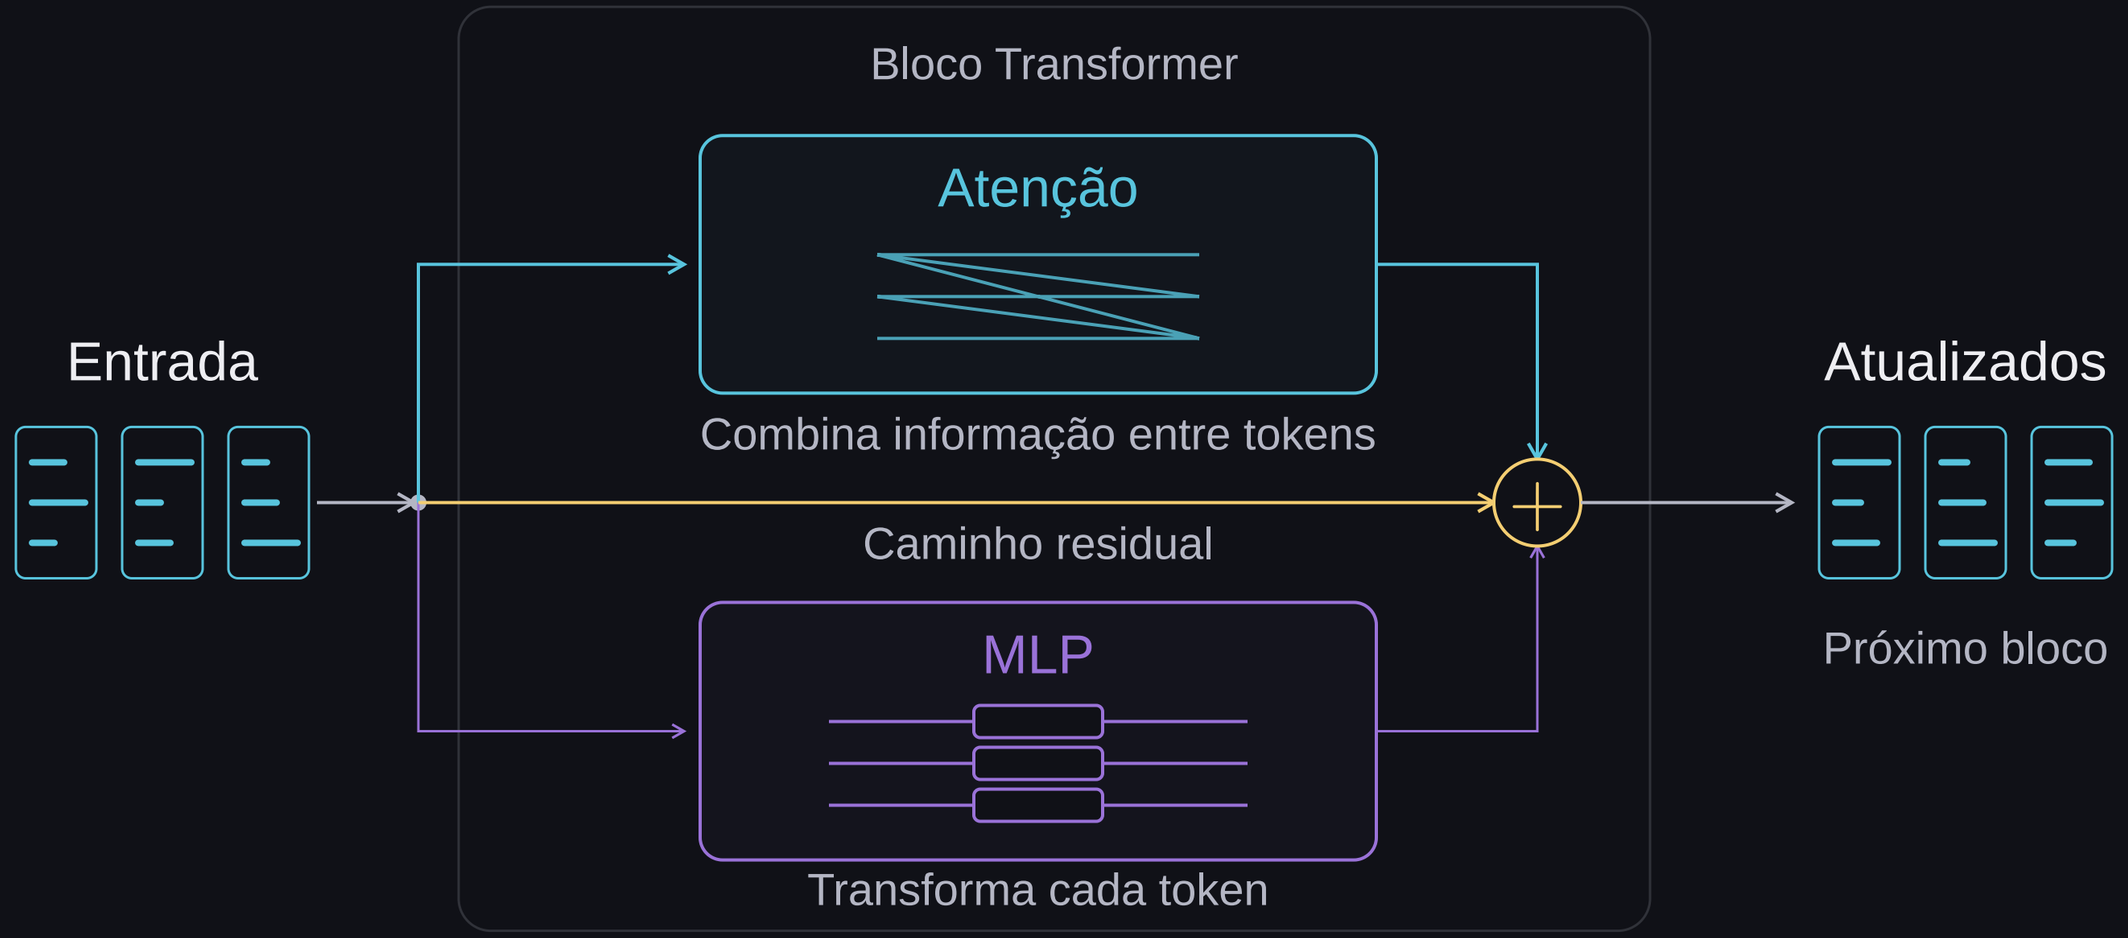
Como o modelo *gera texto?*



Das palavras aos *vetores.*

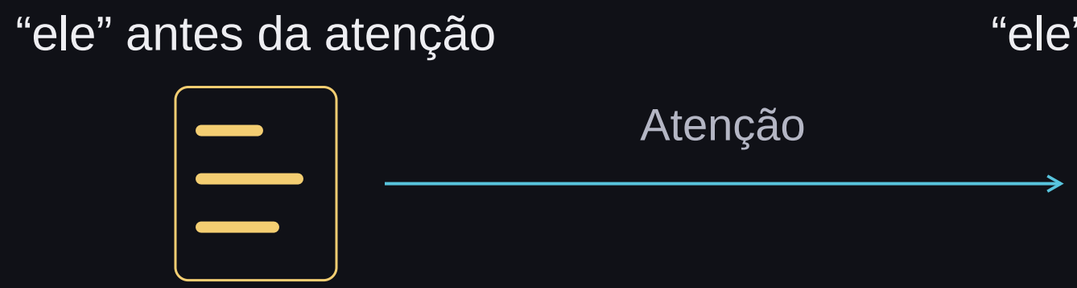


Um bloco do *Pythia-1B*.



O contexto muda a *representação.*





Query (Q)

Como um token pode consultar outros tokens?

A	fluffy	blue	creature	roamed	the	verdant	forest.
	felpuda	azul	criatura				

Vetor de “creature”



x_i

Matriz aprendida

Query (consulta)

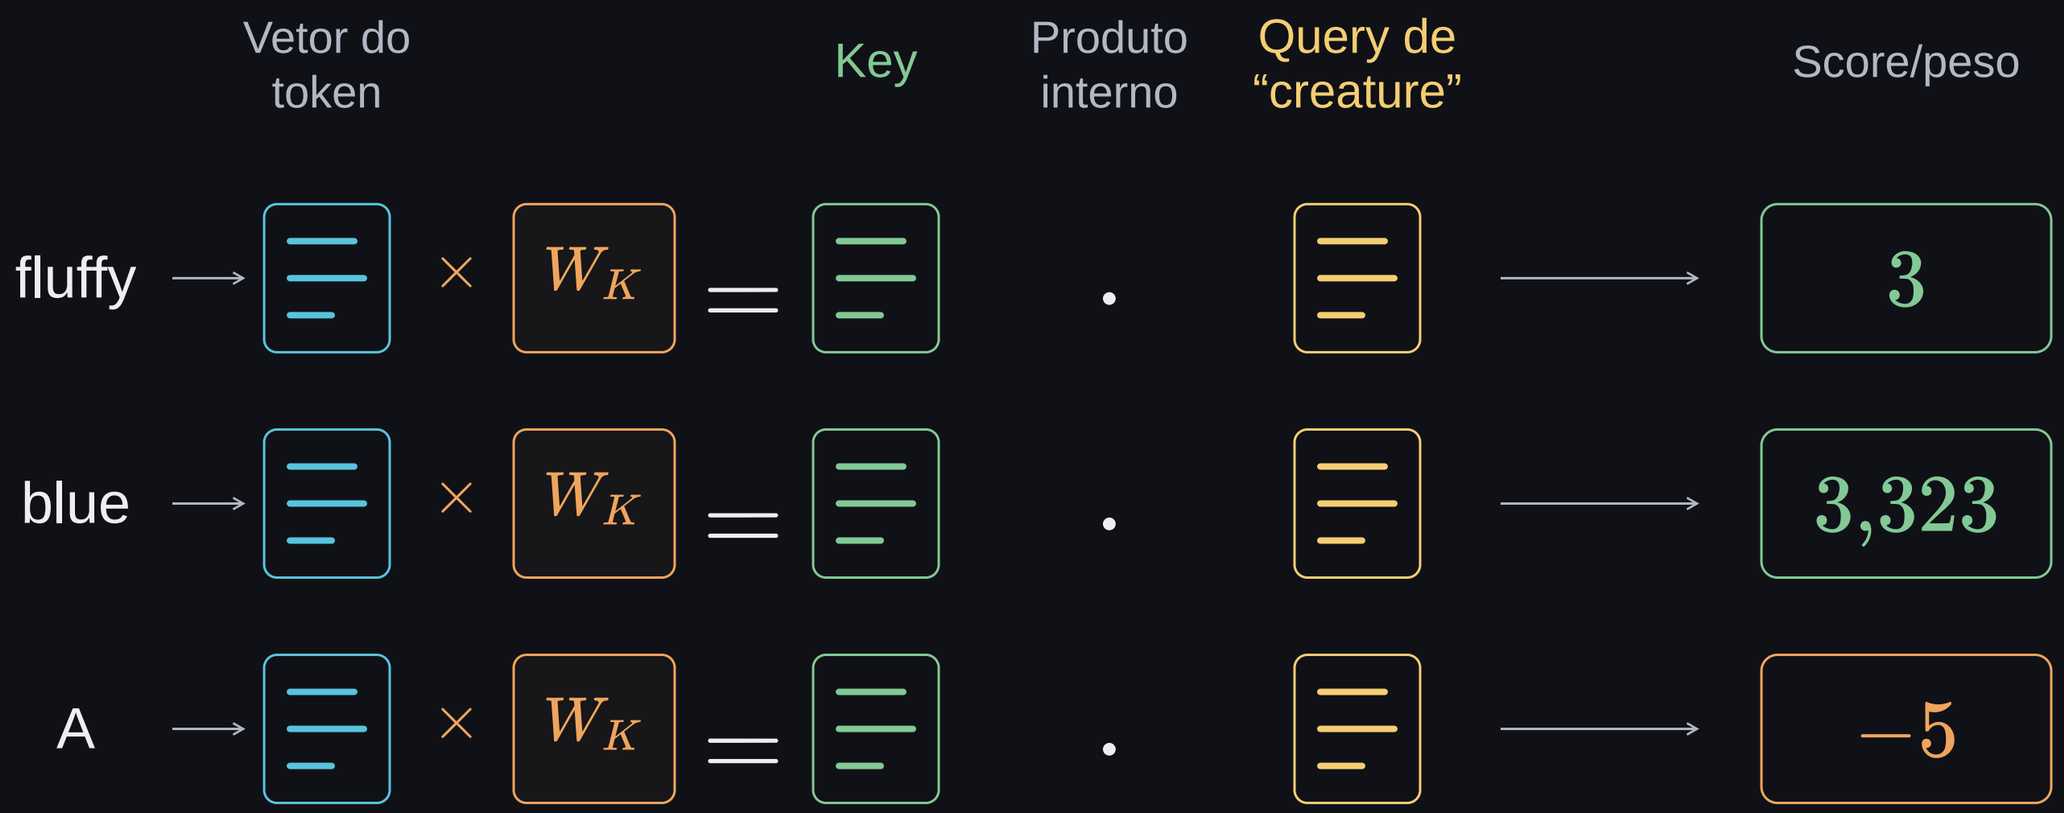
q_i

“Que características descrevem esta criatura?”

$$q_i = x_i W_Q$$

Key (K)

Como um token pode responder a outros tokens?



Padrão de *atenção.*

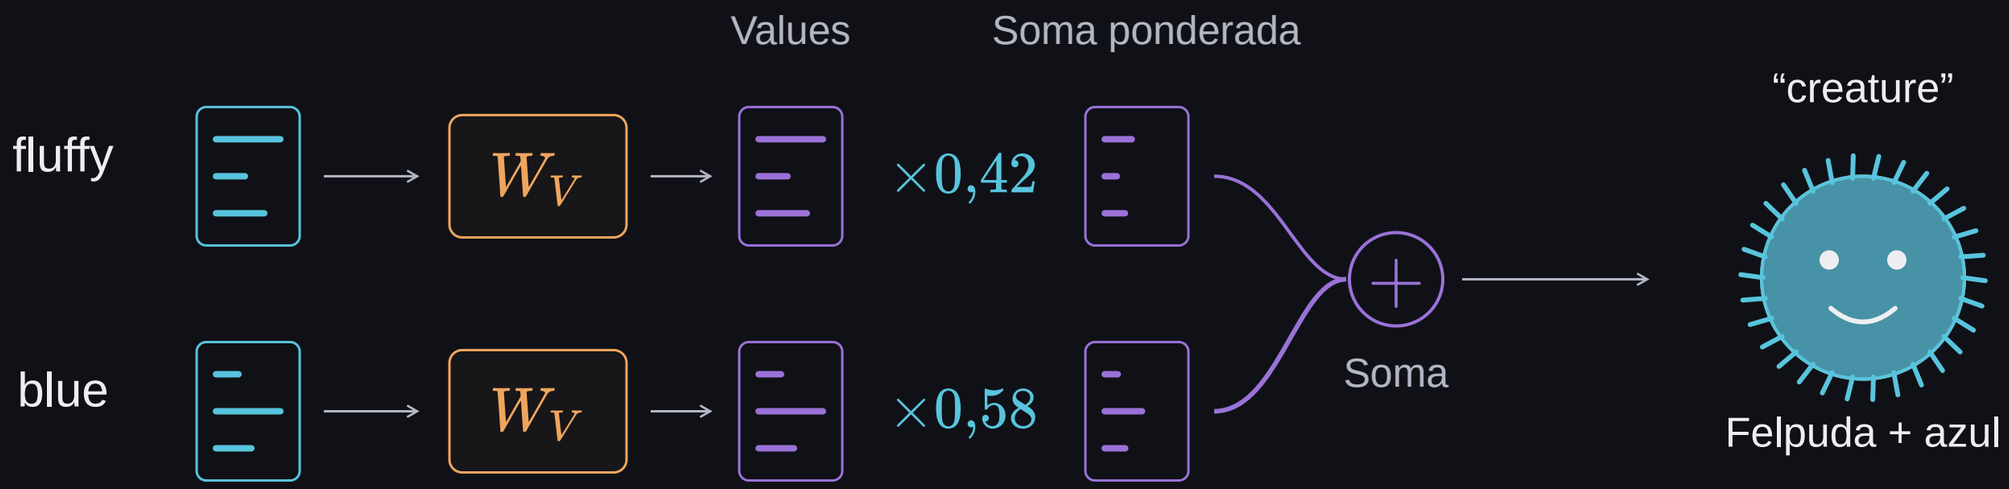


softmax por coluna ⟶ Distribuição de probabilidades

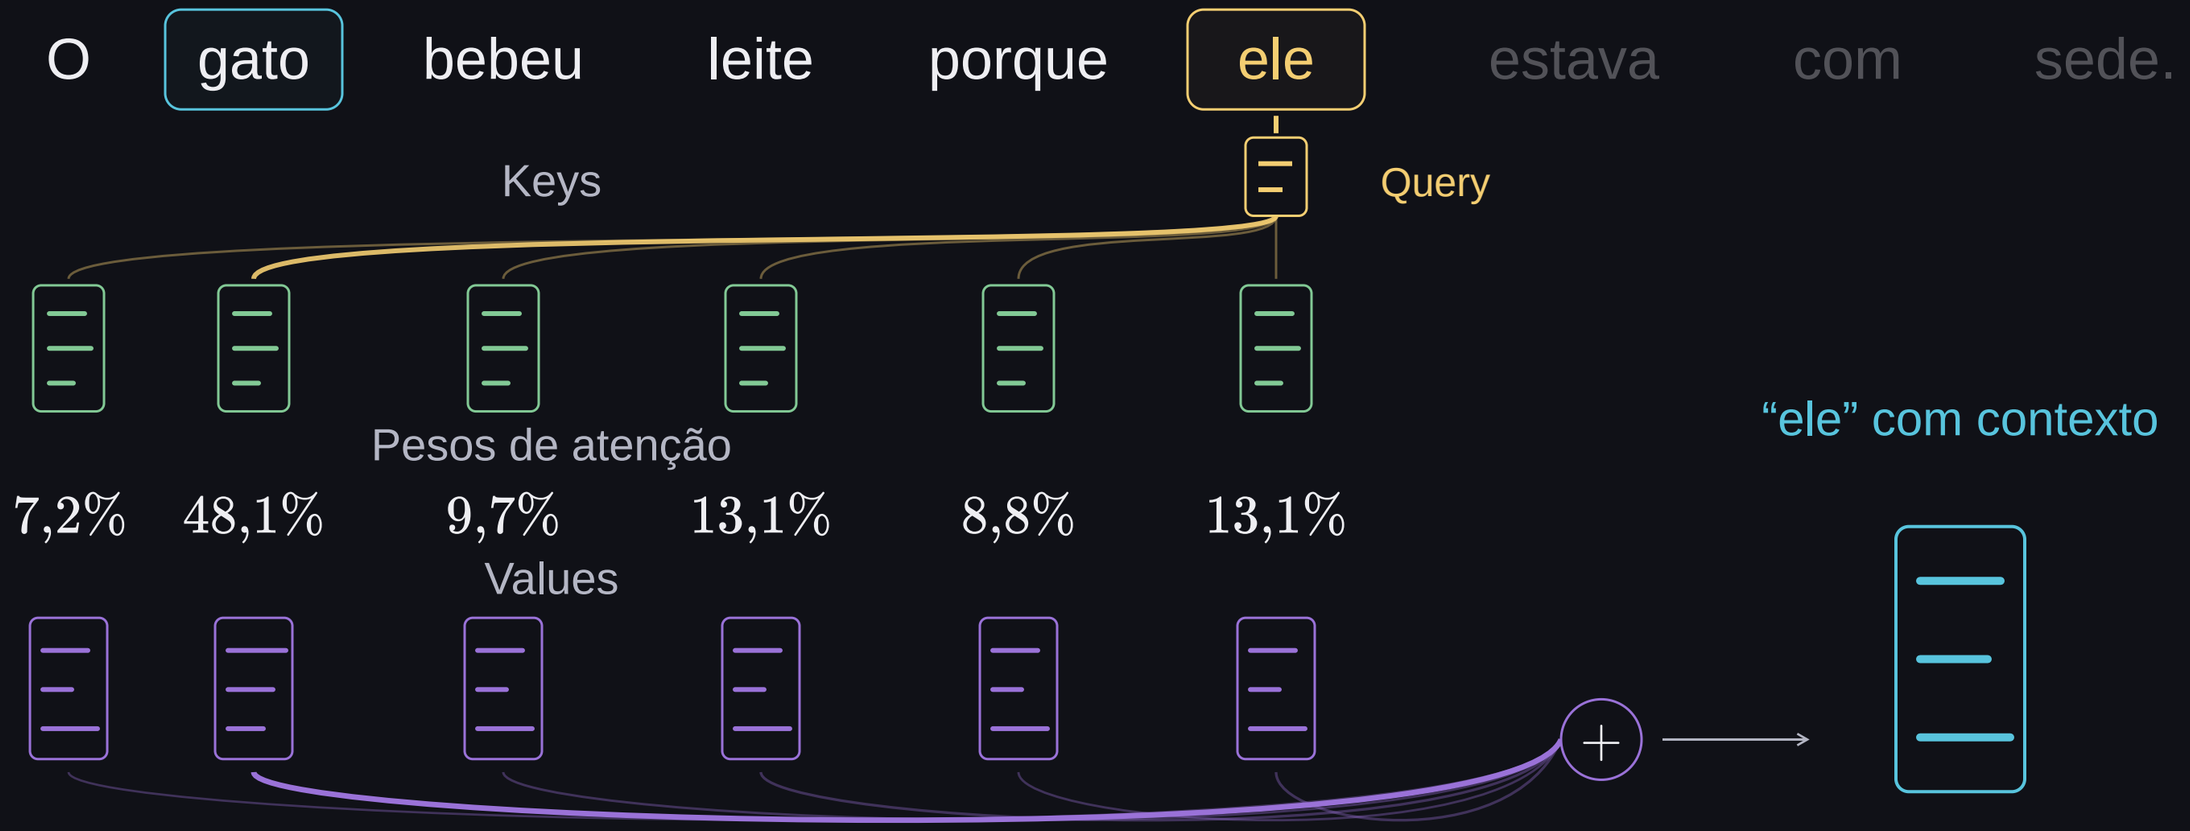
Value (V)

Como transferir informação de um token para outro?

A fluffy blue **creature** roamed the verdant forest.

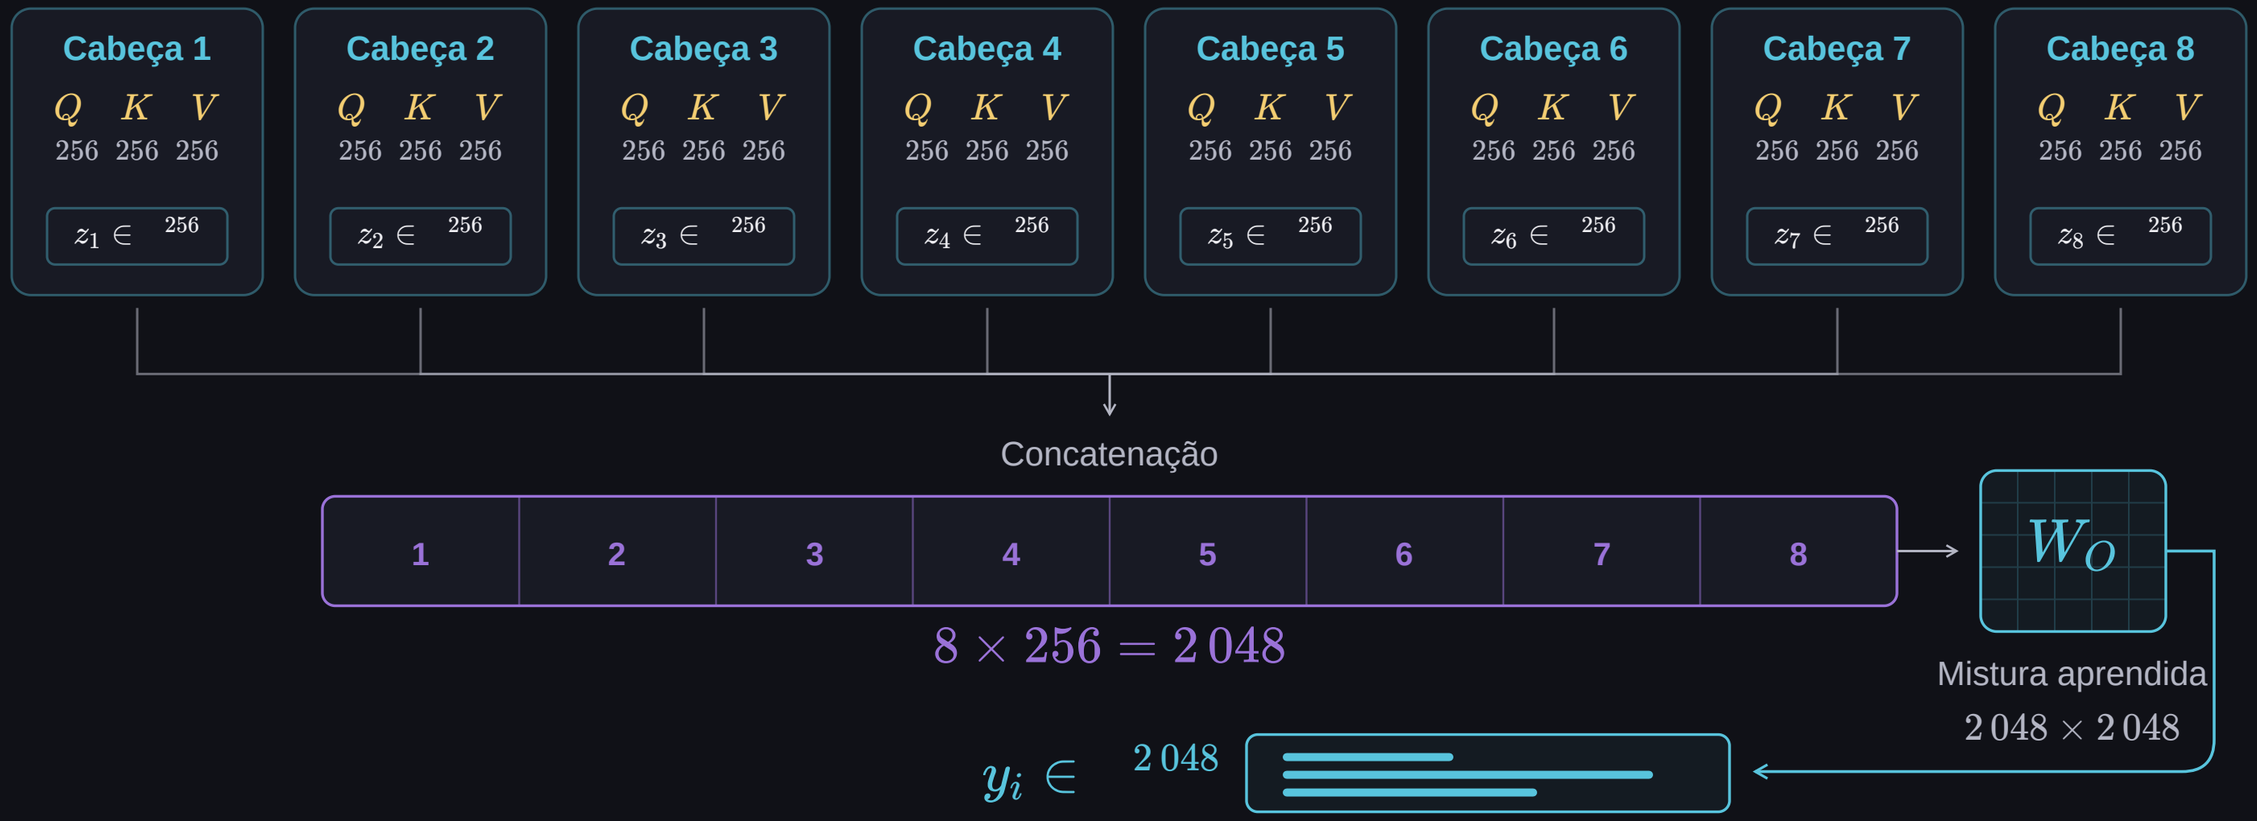


De “gato” a *“ele”*.


O
gato
bebeu
leite
porque
ele
estava
com
sede.
Keys
Query
Pesos de atenção
7,2%
48,1%
9,7%
13,1%
8,8%
13,1%
Values
“ele” com contexto

Das cabeças à *saída.*

$$d_{\text{head}} = \frac{2\,048}{8} = 256$$

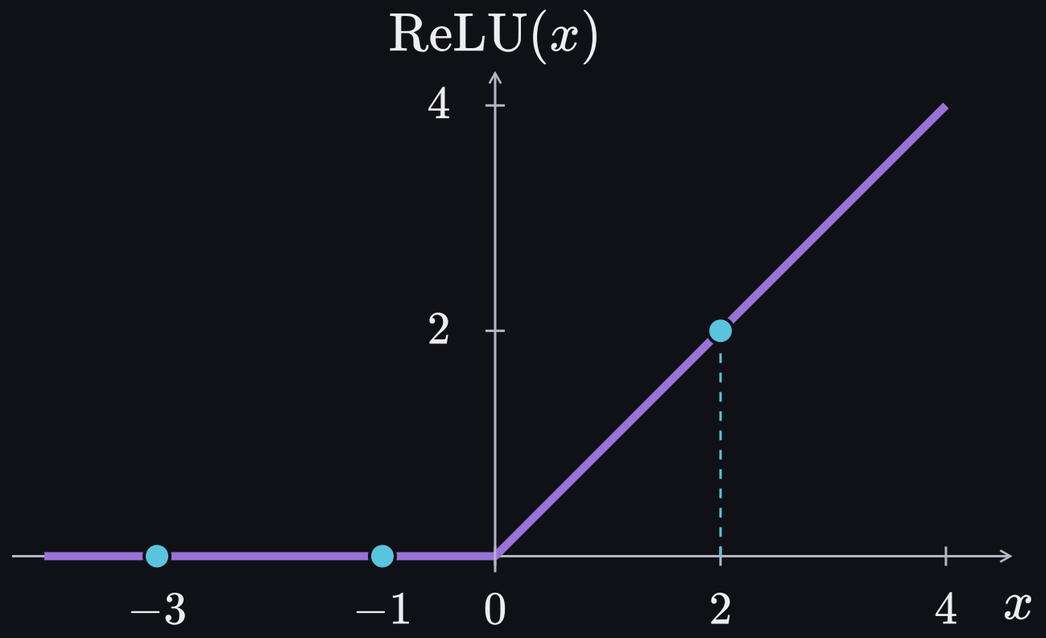


A MLP transforma *cada token.*



ReLU: *introduzindo não linearidade.*

$$\mathrm{ReLU}(x) = \max(0, x)$$

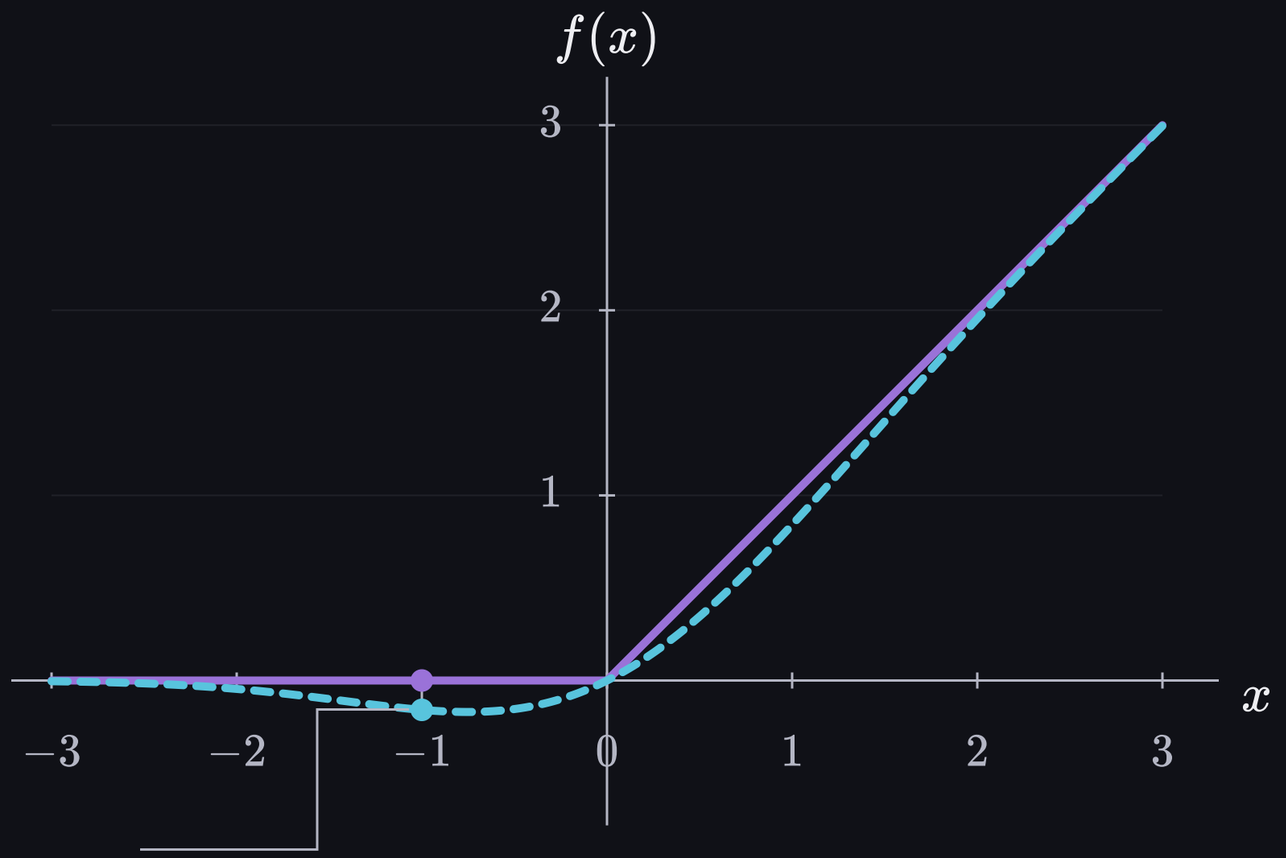


Entrada	Saída
-3	0
-1	0
2	2

MLP → Expansão → ReLU → Projeção

— ATIVAÇÃO

ReLU e *GELU.*



ReLU

$$\mathrm{ReLU}(x) = \max(0, x)$$

Zera entradas negativas

GELU

Atenua em vez de cortar

Gradientes variam suavemente

Pode facilitar o treinamento

— SAÍDA DO MODELO

Do último vetor *ao próximo token.*



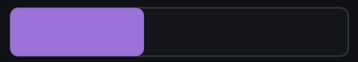
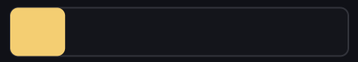
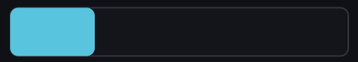
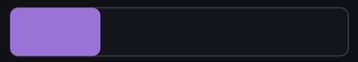
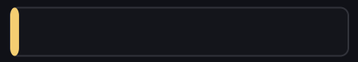
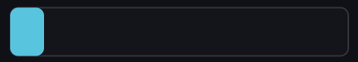
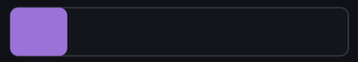
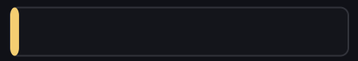
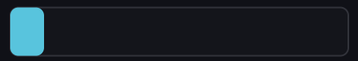
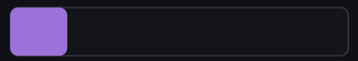
Como funciona a *softmax?*

	Logits	⟶	Exponenciar	⟶	Dividir pela soma
leite	$2{,}40$		$e^{2{,}40} \approx 11{,}02$		$\frac{11{,}02}{20{,}04} \approx 55\%$
água	$1{,}61$		$e^{1{,}61} \approx 5{,}00$		$\frac{5{,}00}{20{,}04} \approx 25\%$
suco	$0{,}70$		$e^{0{,}70} \approx 2{,}01$		$\frac{2{,}01}{20{,}04} \approx 10\%$
chá	$0{,}70$		$e^{0{,}70} \approx 2{,}01$		$\frac{2{,}01}{20{,}04} \approx 10\%$

Soma $\approx 20{,}04$

O efeito da *temperatura.*

Dividir os logits pela temperatura antes da softmax

	Logits	$T = 0{,}5$ Mais concentrada		$T = 1$ Sem ajuste		$T = 2$ Mais distribuída	
leite	2,40		78,6%		55%		39,6%
água	1,61		16,2%		25%		26,7%
suco	0,70		2,6%		10%		16,9%
chá	0,70		2,6%		10%		16,9%

Onde estão *os números aprendidos?*



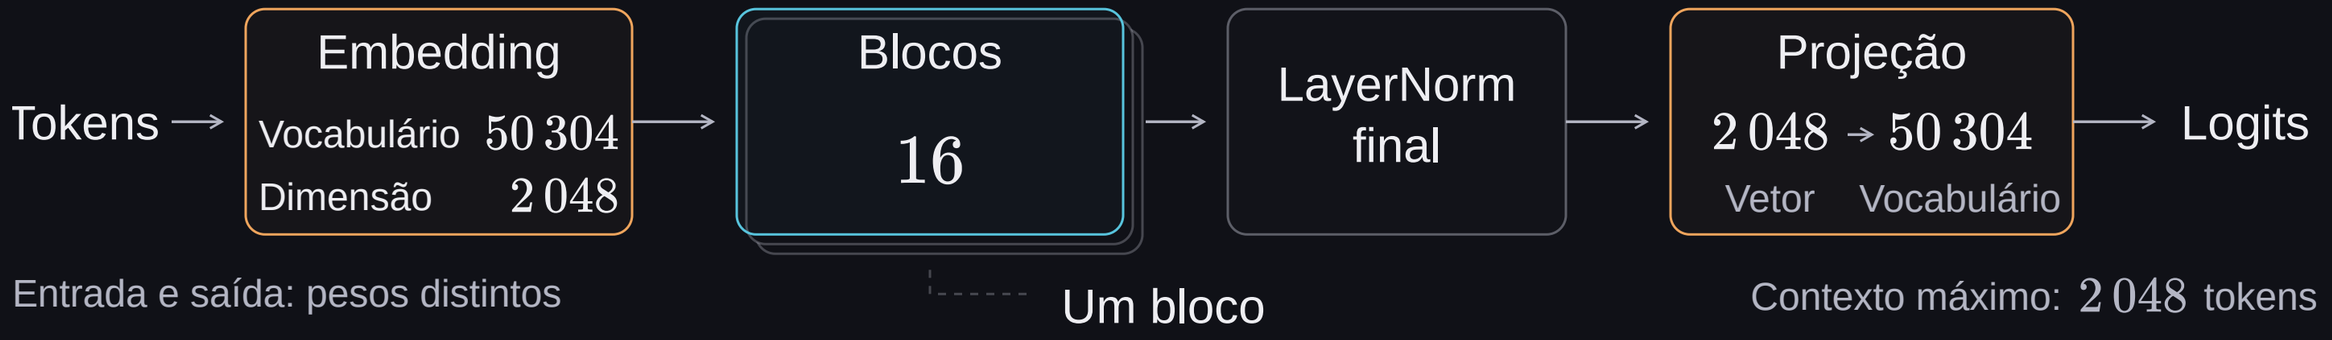
Parâmetros próprios em cada bloco

Normalizações

Bias · posição aprendida

Conforme a arquitetura

Por dentro do *Pythia-1B.*





Contar por *componente.*

Um bloco

Atenção

inclui W_O

8 cabeças

Query: 2 048 → 256

Key: 2 048 → 256

Value: 2 048 → 256

por matriz

Concatenadas: 2 048 → Projeção: 2 048

16 785 408

MLP

2 048 → Expansão → 8 192 → GELU → Projeção → 2 048

33 564 672

Duas LayerNorms

Uma para cada ramo

Atenção	MLP	Total no bloco
4 096	4 096	8 192

Parâmetros por bloco — **50 358 272**

O modelo completo

Embedding	103 022 592
16 blocos	805 732 352
LayerNorm final	4 096
Saída	103 022 592
Total do modelo	**1 011 781 632**

Dos parâmetros *ao arquivo.*

Parâmetros

1 011 781 632

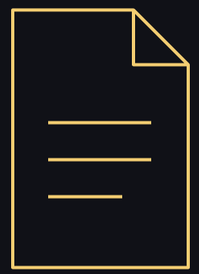
FP16

× 2

bytes / parâmetro

Bytes dos pesos

2 023 563 264



`model.safetensors`

Arquivo em disco

≈ 2,091 GB

\+ Buffers 67 109 920

\+ Cabeçalho 28 344

Total do arquivo · bytes

2 090 701 528

— ENCERRAMENTO

Obrigado!

Para continuar: 3Blue1Brown

CAPÍTULO 05

Transformers

Transformers, the tech behind LLMs

Assistir ao vídeo ↗

CAPÍTULO 06

Atenção

Attention in transformers, step-by-step

Assistir ao vídeo ↗

CAPÍTULO 07

MLP

How might LLMs store facts

Assistir ao vídeo ↗